

PL/O 简易编译器的实现

该实验PL/O编译器结构满足PL/O 语言的文法规范， 目的为应课题要求，完成课业任务，结合上海大学《编译原理课程-实验指导书》，实验项目如下：

目录

- [实验一：识别标识符](#)
- [实验二：词法分析](#)
- [实验三：语法分析](#)
- 实验四：语义分析
- 实验五：中间代码生成
- 实验六：代码优化

项目框架

本项目采用MAVEN搭建，环境为JDK14，IntelliJ IDEA 2019.3.4 (Ultimate Edition)，测试环境JUNIT5

@Author：白皓天

@ID：17121444

@Institution：上海大学计算机工程与科学学院

@Major：计算机科学与技术

标识符的识别

实验内容

输入 PL/O 语言源程序，输出源程序中所有标识符的出现次数。

实验要求

- 识别程序读入 PL/O 语言源程序（文本文件），识别结果也以文本文件保存。
- 按标识符出现的顺序输出结果，每个标识符一行，采用二元式序列，即：(标识符值, 标识符出现次数)
- 源程序中字符不区分大小写，即：“a1”和“A1”是同一个标识符。
- 准备至少 5 组测试用例，每组测试用例包括：输入源程序文件和输出结果。
- 测试用例应该考虑各种合法标识符的组合情况。

输入输出样例

输入：（文本文件）

```

1  Const num=100;
2  Var a1,b2;
3  Begin
4  Read(A1);
5  b2:=a1+num;
6  write(A1,B2);
7  End.

```

输出：（文本文件）

```

1  (num: 2)
2  (a1: 4)
3  (b2: 3)

```

实验分析

根据[标识符定义](#)以及[EBNF元符号](#)的说明可知：

标识符可以描述为：以字母开头的字母与数字的组合。

而根据实验要求：应当读入，输出文件，

因此，本次实验共有两个分步骤：

- 创建文件读入和输出I/O类，输入输出txt文件
- 编写Identifiers.java 抽象类，其实现的主要功能有：
 - 区分关键字，运算符与合法的标识符
 - 以二元组的形式输出合法标识符的数目统计结果

文法类？

即对源程序给出精确无二义的语法描述。（严谨、简洁、易读），根据文法定义四元组：

文法**G**定义为四元组（**VN**，**VT**，**P**，**S**）

- **VN**：非终结符集

- **VT**：终结符集

- **P**：产生式（规则）集合

- **S**：开始符号，**S** ∈ **VN**，**S**必须要在一条规则的左部出现。

VN ∩ **VT** = \varnothing

V = **VN** ∪ **VT**，称为文法**G**的文法符号集合

标识符的文法定义如下：

文法**G** = （**VN**，**VT**，**P**，**S**）

VN = {标识符，字母，数字}

VT = {a,b,c,...,x,y,z,0,1,...,9}

P = {<标识符> → <字母>

<标识符> → <标识符> <字母>

<标识符> → <标识符> <数字>

<字母> → a,..., <字母> → z

<数字> → 0,..., <数字> → 9 }


S = <标识符>

如何利用文法判定标识符是否合法呢？有两种方案，自顶向下与自顶向下，通过剪枝文法树的方式，判断合法性。

举个例子：设产生式集合：

$P = \{ A \rightarrow 0A1, A \rightarrow 01 \}$ 判断000111是否合法

A为文法G的开始符号




注：前面所讲为查阅资料之前的想法

在阅读了几篇文献后，发现这样做（文法类的建立）虽然可行，但具有以下不足：


- 定义剪枝条件：如上图，运用 $A \rightarrow 01$ 推导，因为此时没有A，无法再“延长”字符串以达到要求，但这是文法类做的事情么。如果产生式改变，这个推到条件又得变化了，如 $0A1 \rightarrow A$ ，要求“缩短”，故无法达到整合处理的目的。
- 其实熟悉状态机后会发现，prune的子树回到了开始状态，如果转换成图，节省了判断剪枝条件，并且数据结构也变得简单。【这也是主流编译器通用的词法分析手段】

状态机



引用一位博主在介绍状态机时举的例子【1】，我们日常生活中，灯关闭时，打开，为开启状态；再关闭，回到关闭状态；开启时同上。其实很多程序内部我们都用到了状态机的方法，只不过较为隐晦。

在状态有限的条件下，也就是常说的FSM（finite state machine），对该方法最为直接的运用便是正则表达式。



1: A→01; 2: A→0A1; 0...1...表示相同个数的0和1

对于上方的状态转换可以该图描述。

正则表达式

正则表达式，与用EBNF描述语法的形式颇有类似，及无二义性地对概念进行定义。

不过当前，很多主流语言如java, python, c++都对正则表达式有了充分支持，正则表达式只是描述，但最为核心的一点是，任何的正则表达式都可以用**FSM**表示，所以我们使用正则表达式进行字符串匹配的时候：

可以知道其实经过了以下步骤：

1. 将正则表达式转换成FSM
2. 生成FSM代码


FSM代码的思路通常为：

```
1 state = start_state
2 input = get_next_input
3 while not end of input do
4     state = move(state, input)
5     input = get_next_input
6 endif state is a final state
7     return "ACCEPT" else return "REJECT"
```

所以第二步也是十分清晰的。

实现

摸着石头过河必定会花费大量时间，但有时候也是值得的，特别是想要思考来龙去脉的时候。但要进行实现的时候，参考前人的经验，既可以激发思绪，也可以节省大量尝试时间。想要搭建较为满意的编译器，采用现有的结构框架是一个很好的做法。



这是著名的Dragon Book2 中的编译器的前端模型，后面内容会继续引用该图：

目前，要做的为Lexical Analyzer，

主要功能用一句话概括为：读入输入流转化为tokens对象组。

1.定义Tag类

```

1 public enum Tag {
2     ID("[a-zA-Z][0-9]|[a-zA-Z]*"),
3     NUM("[0-9]+"),
4     OPE("\\+|-|\\*|/|=|#|<|<=|>|>=|:=|"),
5     DELIMITER("\\(|\\)|{|}|\\.|\""),
6
7     BASIC("begin|call|const|do|end|if|odd|procedure|read|then|var|while|write"
8 );
9
10    public final String pattern;
11
12    Tag(String pattern) {
13        this.pattern = pattern;
14    }
15 }

```

以描述tokens的类别

测试结果如下：（通过测试）

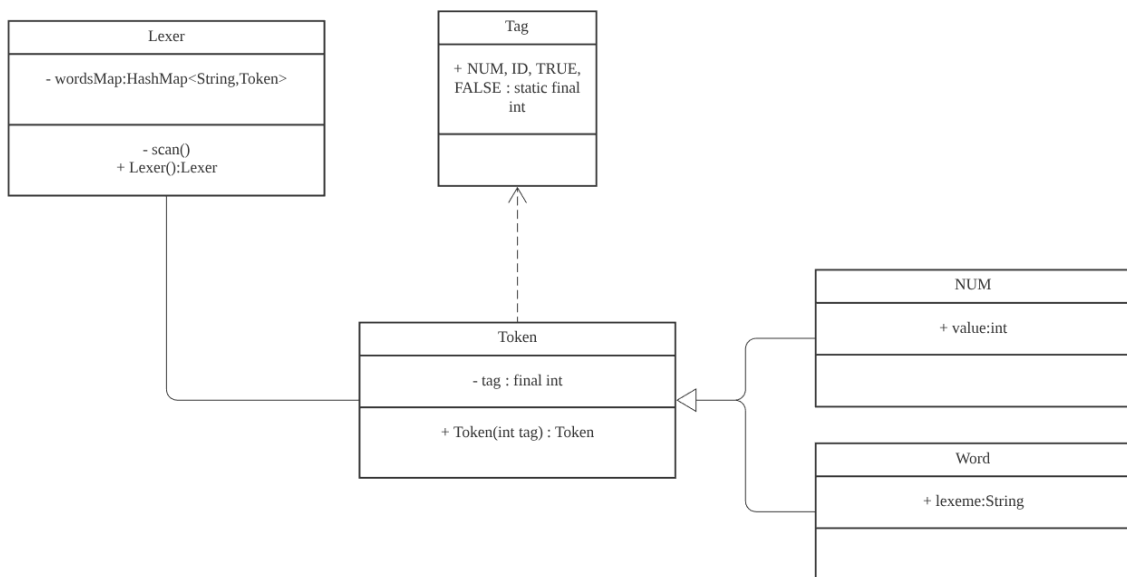
```
1 // NUM
2 assertTrue(Pattern.matches(Tag.NUM.pattern, "555666600"));
3 assertFalse(Pattern.matches(Tag.NUM.pattern, "555xe2"));
4 // ID
5 assertTrue(Pattern.matches(Tag.ID.pattern, "u123x"));
6 assertFalse(Pattern.matches(Tag.ID.pattern, "12Uddd"));
7 // OPE
8 assertTrue(Pattern.matches(Tag.OPE.pattern, "+"));
9 assertTrue(Pattern.matches(Tag.OPE.pattern, "-"));
10 assertTrue(Pattern.matches(Tag.OPE.pattern, "*"));
11 assertTrue(Pattern.matches(Tag.OPE.pattern, "/"));
12 assertTrue(Pattern.matches(Tag.OPE.pattern, "="));
13 assertTrue(Pattern.matches(Tag.OPE.pattern, ":="));
14 assertTrue(Pattern.matches(Tag.OPE.pattern, "#"));
15 assertTrue(Pattern.matches(Tag.OPE.pattern, "<="));
```

```

16     assertTrue(Pattern.matches(Tag.OPE.pattern, ">="));
17     // BASIC
18     assertTrue(Pattern.matches(Tag.BASIC.pattern, "begin"));
19     // DELIMITER
20     assertTrue(Pattern.matches(Tag.DELIMITER.pattern, ")"));
21     assertTrue(Pattern.matches(Tag.DELIMITER.pattern, "("));
22     assertTrue(Pattern.matches(Tag.DELIMITER.pattern, ")"));
23     assertTrue(Pattern.matches(Tag.DELIMITER.pattern, "("));
24     assertTrue(Pattern.matches(Tag.DELIMITER.pattern, ","));
25     assertTrue(Pattern.matches(Tag.DELIMITER.pattern, ";"));
26     assertTrue(Pattern.matches(Tag.DELIMITER.pattern, "."));

```

2. UML类图



整个项目结构清晰，Lexer将输入的字符处理，主要用scan（）调用Tag中的NUM，与ID的识别方法，从而构建了相应的Token，并放入HashMap以存储字。

为了实验需要，有设置了一个专门统计Identifier的HashMap。

如此得到结果。

3. 一个关键问题

老师的测试数据任然不算严格，例如正常编译器中，有 $3+2>4$ ，而非 $3 + 2 > 4$ ，这样规范的写法，如何识别连续输入的字符串呢？

这里Tag中的正则表达式发挥了作用：

1. 匹配所有满足表达式的结果并储存。
2. 字符串缩进，提高效率。

关键还是正则表达式，可见上方[Tag类定义](#)。

测试用例结果

举一个例子，其余的请见测试resources文件夹：

case02.txt

```

1  CONST  A=10;

```

```

2  VAR   B,C;
3  PROCEDURE  P;
4      VAR D;
5      PROCEDURE  Q;
6          VAR X;
7          BEGIN
8              READ(X);
9              D:=X;
10             WHILE X#0
11                 DO CALL P;
12             END;
13         BEGIN
14             WRITE(D);
15             CALL Q;
16         END
17 BEGIN
18     CALL P;
19 END.
20

```

result/case02Result.txt

```

1  (X: 4)
2  (D: 3)
3  (C: 1)
4  (B: 1)
5  (Q: 2)
6  (A: 1)
7  (P: 3)

```

可见结果正确。

我加入了注释功能，如java的// 与 /* */

测试用例：homework_1.txt

```

1  // 编写一个PL/O程序，输入3个正整数a、b、c，按从小到大的顺序输出这三个数
2  var a,b,c,t;
3  begin
4      read(a);
5      read(b);
6      read(c);
7      if a > b then
8          begin
9              t := b;
10             b := a;
11             a := t;
12         end
13     if b > c then
14         begin
15             t := b;
16             b := c;
17             c := t;
18         end
19     if a > c then
20         begin
21             t := a;

```

```

22         a := c;
23         c := t;
24     end
25 begin
26     write(a);
27     write(b);
28     write(c);
29 end
30 end

```

结果:

```

1  (t: 7)
2  (a: 9)
3  (c: 9)
4  (b: 9)

```

后续工作

接下来就是变量表，文法，报错等内容，都留下了一些接口。总的来说，第一次工作量挺大，查资料，写代码，测试，整个周末都搭进去了，但收获明显：正则表达式，FSM，编译器基本框架。

词法分析

一、实验目的：

1. 根据 PL/0 语言的 文法规范，编写 PL/0 语言的词法分析程序。
2. 通过设计调试词法分析程序，实现从源程序中分出各种单词的方法；加深对课堂教学的理解；提高词法分析方法的实践能力。
3. 掌握从源程序文件中读取有效字符的方法和产生源程序的内部表示文件的法。
4. 掌握词法分析的实现方法。
5. 上机调试编出的词法分析程序。

二、实验内容：

输入PL/0语言程序，输出程序中各个单词符号（关键字、专用符号以及其它标记）。

三、实验要求：

1. 确定编译中单词种类、使用的表格、标识符与关键字的区分方法等。
2. 词法分析器读入PL/0语言源程序（文本文件），识别结果也以文本文件保存。
3. 词法分析器的输出形式采用二元式序列，即：

(单词种类,单词的值)

4. 源程序中字符不区分大小写，即：“a1”和“A1”是同一个标识符。
5. 准备至少5组测试用例，每组测试用例包括：输入源程序文件和输出结果。
6. 测试用例必须包含所有的基本字、运算符、界符、以及各种标识符和常数。对不合法单词进行分类考虑测试用例，特别是对一些运算。

四、实验过程：

1. 设计思路

在上一个步骤中，已经基本实现了词法分析，即将一段源代码作为输入，能够正确区分词的类型。这一步是对[上面](#)的补充。

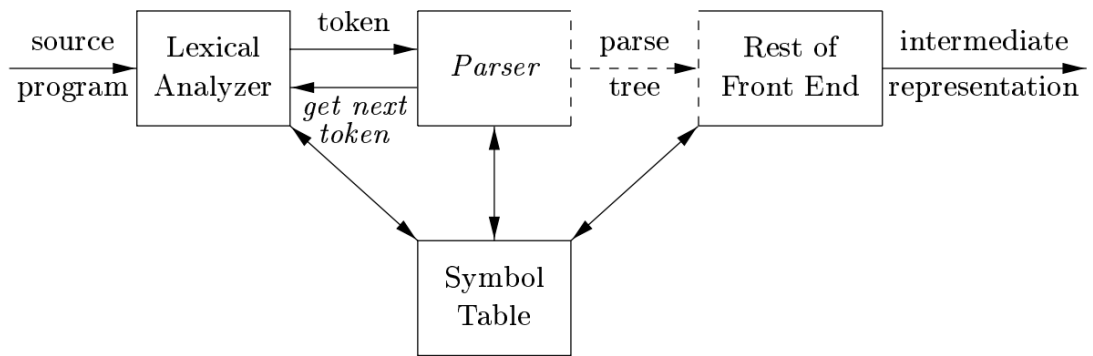
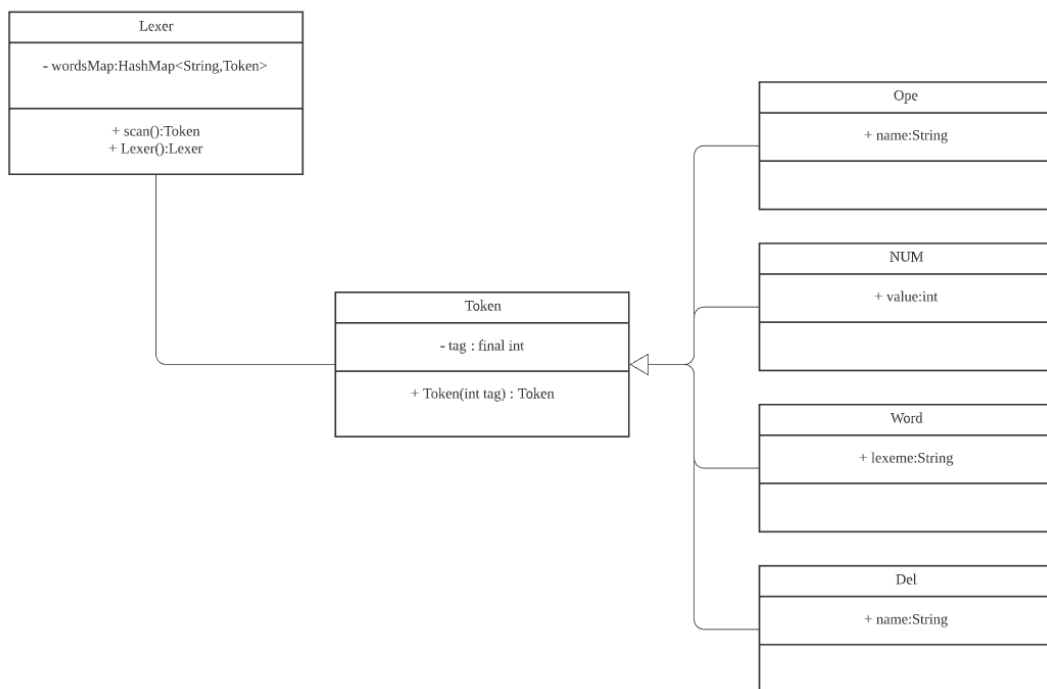


Figure 4.1: Position of parser in compiler model

由于上次对Lexical Analyzer的功能有少许误解，这次修改scan（）功能，以只得到一个套接字。以方便后续Parser的编写。

修改后的设计UML类图如下：



2. 实验结果

举一个例子：case01.txt

```

1  var
2
3      x,y,z;
4
5  begin
6
7      x := 10;
8
9      y := -5;
10
11     read(z);
12
13     if z > 3 then
14
15         write(x)

```

```
16
17     else
18
19         write(y);
20
21 end.
22
```

结果:

```
1  (VAR, var)
2  (ID, x)
3  (Del, comma)
4  (ID, Y)
5  (Del, comma)
6  (ID, Z)
7  (Del, semicolon)
8  (BEGIN, begin)
9  (ID, x)
10 (OPE, becomes)
11 (NUM, 10)
12 (Del, semicolon)
13 (ID, Y)
14 (OPE, becomes)
15 (OPE, minus)
16 (NUM, 5)
17 (Del, semicolon)
18 (READ, read)
19 (Del, lParen)
20 (ID, Z)
21 (Del, rParen)
22 (Del, semicolon)
23 (IF, if)
24 (ID, Z)
25 (OPE, greaterThan)
26 (NUM, 3)
27 (THEN, then)
28 (WRITE, write)
29 (Del, lParen)
30 (ID, x)
31 (Del, rParen)
32 (ELSE, else)
33 (WRITE, write)
34 (Del, lParen)
35 (ID, Y)
36 (Del, rParen)
37 (Del, semicolon)
38 (END, end)
39 (Del, period)
40
```

五、结论及体会:

此次实验较为简单, 但然我弄明白了基本的词法分析的功能, 每次一个套接字, 比起多个一起识别, 还稍微复杂一点, 因为有了Pattern 这样方便的道具。

语法分析

一、实验目的：

1. 实验目的

- 给出 PL/0 文法规范，要求编写 PL/0 语言的语法分析程序。
- 通过设计、编制、调试一个典型的语法分析程序，实现对词法分析程序所提供的单词序列进行语法检查和结构分析，进一步掌握常用的语法分析方法。
- 选择一种语法分析方法（递归子程序法、LL(1)分析法、算符优先分析法、SLR(1)分析法）；选择常见程序语言都具备的语法结构，如赋值语句，特别是表达式，作为分析对象。

二、实验内容：

- 已给 PL/0 语言文法，构造表达式部分的语法分析器。
- 分析对象〈算术表达式〉的 BNF 定义如下：
<表达式> ::= [+|-]<项>{*<加法运算符> <项>}
<项> ::= <因子>{*<乘法运算符> <因子>}
<因子> ::= <标识符> | <无符号整数> | '(<表达式>')'
<加法运算符> ::= +|-
<乘法运算符> ::= *|/

学有余力的同学，可适当扩大分析对象。譬如：

- ① 除表达式（算术表达式）外，扩充对条件表达式的语法分析。
- ② 表达式中变量名可以是一般标识符，还可含一般常数、数组元素、函数调用等等。
- ③ 加强语法检查，尽量多和确切地指出各种错误。
- ④ 直接用 PL/0 表达式源语言作为输入，例如：(a+15)*b 作为输入。

三、实验要求：

- 确定语法分析的方法。
- 将实验二“词法分析”的输出结果，作为表达式语法分析器的输入，进行语法解析，对于语法正确的表达式，报告“语法正确”；
- 对于语法错误的表达式，报告“语法错误”，指出错误原因。
- 源程序中字符不区分大小写，即：“a1”和“A1”是同一个标识符。
- 准备至少 10 组测试用例，每组测试用例包括：输入文件和输出结果。

四、实验过程：

Big Picture




Figure 4.1: Position of parser in compiler model

引用Dragon Book2，这一张图展示了Parser的两个主要功能

- 最重要的功能，即建立语法分析树，从Lexical Analyzer中取出token。【注：不一定是树结构】
- 维护标识符表，不同的函数生命周期中依次建立一张表，对程序中的变量进行查找和改写。

当然，作为附加功能，检查语法功能可以作为Parser的附加项。

解析算法

构造语法树解析语法，有如通用算法，Top Down，以及Bottom Up。通用算法如Cocke-Younger-Kasami

algorithm 和 Earley's algorithm几乎可以解析任何语法。我选择构造LL语法解析器，其原因主要有：

1. LL语法固然有一定局限，例如进能够识别满足LL语法规则的句子，但已足以面对大多数情况。
2. LL实现简单，有利于手工实现。
3. 方便自己复习已经学过的知识，加深印象

基于以上原因，我选择了LL。

LL的主要功能就是预测，计算FOLLOW, FIRST, SELECT 集为节点下行选择提供判定基础。

- FIRST

$FIRST(\alpha)$ 表示以 α 开头的开始符号集[2]：(仅限下一选择的所有可能项)

$$FIRST(\alpha) = \{a | \alpha \xrightarrow{*} a\beta, a \in V_T, \alpha, \beta \in V^*\} \quad (1)$$

算法：

1. If X is a terminal, then $FIRST(X) = \{X\}$.
2. If X is a nonterminal and $X \rightarrow Y_1 Y_2 \cdots Y_k$ is a production for some $k \geq 1$, then place a in $FIRST(X)$ if for some i , a is in $FIRST(Y_i)$, and ϵ is in all of $FIRST(Y_1), \dots, FIRST(Y_{i-1})$; that is, $Y_1 \cdots Y_{i-1} \xrightarrow{*} \epsilon$. If ϵ is in $FIRST(Y_j)$ for all $j = 1, 2, \dots, k$, then add ϵ to $FIRST(X)$. For example, everything in $FIRST(Y_1)$ is surely in $FIRST(X)$. If Y_1 does not derive ϵ , then we add nothing more to $FIRST(X)$, but if $Y_1 \xrightarrow{*} \epsilon$, then we add $FIRST(Y_2)$, and so on.
3. If $X \rightarrow \epsilon$ is a production, then add ϵ to $FIRST(X)$.

- FOLLOW

$FOLLOW(A)$ 表示以开A头的后跟符号集[2]（同理）

$$FOLLOW(A) = \{a | \mu A \beta \text{ 且 } a \in V_T, a \in FIRST(\beta), \mu \in V_T^*, \beta \in V^+\} \quad (2)$$

一张图可以清晰的理解这两个概念上的差别。




Figure 4.15: Terminal c is in $\text{FIRST}(A)$ and a is in $\text{FOLLOW}(A)$

有点像DFS（深度优先遍历）与BFS（广度优先遍历），只不过不同的是这里的作用是预测A之后的行径，那么关注点限制了范围，即A的子孙节点，以及兄弟节点（仅右方）；或许A, a之间还有一些点，但都会被消掉（ ϵ ），假如a是下一个要取得话。

To compute $\text{FOLLOW}(A)$ for all nonterminals A , apply the following rules until nothing can be added to any FOLLOW set.

1. Place $\$$ in $\text{FOLLOW}(S)$, where S is the start symbol, and $\$$ is the input right endmarker.
2. If there is a production $A \rightarrow \alpha B \beta$, then everything in $\text{FIRST}(\beta)$ except ϵ is in $\text{FOLLOW}(B)$.
3. If there is a production $A \rightarrow \alpha B$, or a production $A \rightarrow \alpha B \beta$, where $\text{FIRST}(\beta)$ contains ϵ , then everything in $\text{FOLLOW}(A)$ is in $\text{FOLLOW}(B)$.

• SELECT

对于上下文无关文法产生式：

$A \rightarrow \alpha, A \in V_N, \alpha \in V^*, \text{若 } \alpha \not\Rightarrow \epsilon, \text{ 则 } \text{SELECT}(A \rightarrow \alpha) = \text{FIRST}(\alpha)$

若 $\alpha \Rightarrow \epsilon$, 则 $\text{SELECT}(A \rightarrow \alpha) = \text{FIRST}(\alpha - \{\epsilon\}) \cup \text{FOLLOW}(A)$

构建转换表

Algorithm 4.31: Construction of a predictive parsing table.

INPUT: Grammar G .

OUTPUT: Parsing table M .

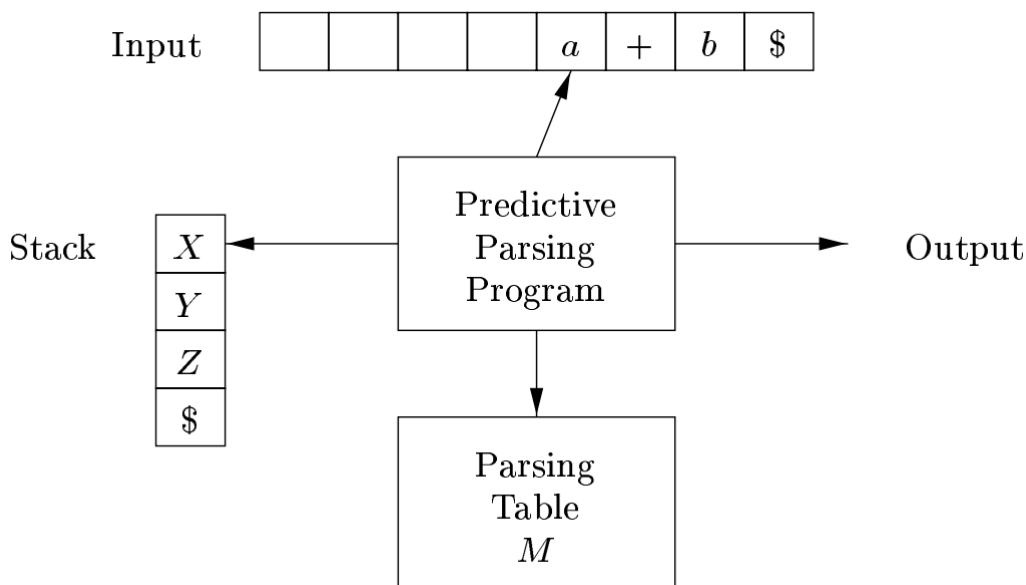
METHOD: For each production $A \rightarrow \alpha$ of the grammar, do the following:

1. For each terminal a in $\text{FIRST}(\alpha)$, add $A \rightarrow \alpha$ to $M[A, a]$.
2. If ϵ is in $\text{FIRST}(\alpha)$, then for each terminal b in $\text{FOLLOW}(A)$, add $A \rightarrow \alpha$ to $M[A, b]$. If ϵ is in $\text{FIRST}(\alpha)$ and $\$$ is in $\text{FOLLOW}(A)$, add $A \rightarrow \alpha$ to $M[A, \$]$ as well.

If, after performing the above, there is no production at all in $M[A, a]$, then set $M[A, a]$ to **error** (which we normally represent by an empty entry in the table). \square

如果用树来表示的话，即是首先DFS遍历，如果没找到下一个，那么进行BFS，如果BFS还没找到，说明不符合LL语法。

预测算法实现



```

let  $a$  be the first symbol of  $w$ ;
let  $X$  be the top stack symbol;
while (  $X \neq \$$  ) { /* stack is not empty */
    if (  $X = a$  ) pop the stack and let  $a$  be the next symbol of  $w$ ;
    else if (  $X$  is a terminal ) error();
    else if (  $M[X, a]$  is an error entry ) error();
    else if (  $M[X, a] = X \rightarrow Y_1 Y_2 \cdots Y_k$  ) {
        output the production  $X \rightarrow Y_1 Y_2 \cdots Y_k$ ;
        pop the stack;
        push  $Y_k, Y_{k-1}, \dots, Y_1$  onto the stack, with  $Y_1$  on top;
    }
    let  $X$  be the top stack symbol;
}
  
```

好了，基本的思路有了，但是在正式开始之前，还有一个基本的问题没有解决，因为用户输入的语法规则，毕竟不一定对LL语法是适合的，还需要包括消除左递归，提取左公因子，消除不确定性。

语法输入优化

虽然有消除歧义性这一项，在Dragon Book中，但是就课本上的内容而言，是没有的。歧义的产生，大多是if ELSE语句的不规范写法而照成的；PLO中没有else语句，故暂时不做。下面仅进行左递归的消除，左公因子的提取，即将某些不适应于LL语法的表达进行转换。

【DDL近了，优化暂时放一放，框架已经写好了】

消除左递归

对于 $A \xrightarrow{+} A\alpha \mid \beta$:

替换作:

$A \rightarrow A'\beta$

$A' \rightarrow \alpha A' \mid \epsilon$

- 1) arrange the nonterminals in some order A_1, A_2, \dots, A_n .
- 2) **for** (each i from 1 to n) {
- 3) **for** (each j from 1 to $i - 1$) {
- 4) replace each production of the form $A_i \rightarrow A_j\gamma$ by the
 productions $A_i \rightarrow \delta_1\gamma \mid \delta_2\gamma \mid \dots \mid \delta_k\gamma$, where
 $A_j \rightarrow \delta_1 \mid \delta_2 \mid \dots \mid \delta_k$ are all current A_j -productions
- 5) }
- 6) eliminate the immediate left recursion among the A_i -productions
- 7) }

第6行消除直接递归，前面为间接递归。

提取左公因子

对形如 $A \rightarrow \alpha\beta \mid \alpha\gamma$ 转换为:

$A \rightarrow \alpha(\beta \mid \gamma)$

写作:

$A \rightarrow \alpha A', A' \rightarrow \beta \mid \gamma$

METHOD: For each nonterminal A , find the longest prefix α common to two or more of its alternatives. If $\alpha \neq \epsilon$ — i.e., there is a nontrivial common prefix — replace all of the A -productions $A \rightarrow \alpha\beta_1 \mid \alpha\beta_2 \mid \dots \mid \alpha\beta_n \mid \gamma$, where γ represents all alternatives that do not begin with α , by

$$\begin{aligned} A &\rightarrow \alpha A' \mid \gamma \\ A' &\rightarrow \beta_1 \mid \beta_2 \mid \dots \mid \beta_n \end{aligned}$$

Here A' is a new nonterminal. Repeatedly apply this transformation until no two alternatives for a nonterminal have a common prefix. \square

项目UML类图

详细请看附件。

实现

1. 语法产生式定义:

<表达式> ::= [+|-]<项>{<加法运算符> <项>}

<项> ::= <因子>{<乘法运算符> <因子>}

<因子> ::= <标识符> | <无符号整数> | '(<表达式>')'

<加法运算符> ::= +|-

<乘法运算符> ::= *|/

$E \rightarrow AIB$
 $I \rightarrow FC$
 $F \rightarrow D<\text{标识符}>|N<\text{无符号整数}>|(E)$
 $P \rightarrow +|-$
 $M \rightarrow *|/$
 $A \rightarrow P|\epsilon$
 $B \rightarrow P|B|\epsilon$
 $C \rightarrow M|F|C|\epsilon$

FIRST集

这个写了我将近两天，因为实现的时候才发现内部具有递归，而且还需要考虑空这个恼人的玩意，还有对于递归过程中临时的HashSet以实现打表，减少已经做好的操作，另一个HashSet实现合并后表达式的FIRST集合记录。

```

1  /**
2   * Use after making every index decide one production
3   * Recursively check NonTerminal t's targets, and find the NonTerminals
4   * and add with hashmap to save and facilitate.
5   *
6   * @param production production to observe
7   * @param tmpFirstSet results
8   * @return has empty?
9   */
10 private boolean checkNonTerminal(Production production, Set<Token>
11 tmpFirstSet) {
12     // firstSet(not cleaned)
13     HashSet<Token> firstSet = new HashSet<>();
14     // terminal itself
15     if (isTer(production.index)) {
16         tmpFirstSet.add(production.index);
17         return false;
18     }
19     // index is not terminal if there is one in first set map, then
20     skip
21     if (first.containsKey(production.index)) {
22         // firstSet add
23         firstSet.addAll(first.get(production.index));
24         // empty map
25         return firstEmpty.get(production.index);
26     }
27     boolean pEmpty = false;
28
29     // clean first check target, all productions with the same index
30     for (Vector<Token> tokens : production.target) {
31         // check a certain production
32
33         int emptyNum = 0;
34         // check every possible token for a given production
35         for (Token token : tokens) {
36             // only A -> #
37             if (token.context.equals("#")) {
38                 tmpFirstSet.add(token);
39                 firstSet.add(token);

```



```

37         pEmpty = true;
38         // go on
39         continue;
40     }
41     if (isTer(token)) {
42         // the token deduces terminal add to firstSet
43         tmpFirstSet.add(token);
44         firstSet.add(token);
45         // then break the loop and check another production if
there is one
46         break;
47     } else {
48         // nonTerminal and cannot deduce empty if it's in the
map
49         Set<Token> tmp = first.get(token.toNonTerminal());
50         if (tmp != null) {
51             if (tmp.contains(new Token("#"))) {
52                 pEmpty = true;
53             }
54             tmpFirstSet.addAll(tmp);
55             firstSet.addAll(tmp);
56             // check if it contains empty, yes -> go on, no->
break;
57             if(!(tmpFirstSet.contains(new Token("#")))){
58                 // clean tmp
59                 tmpFirstSet.clear();
60                 break;
61             }
62
63             // clean tmp
64             tmpFirstSet.clear();
65         } else {
66             Production p_ =
productions.get(token.toNonTerminal());
67             pEmpty = checkNonTerminal(p_, tmpFirstSet);
68             // add tmpFirstSet to FirstSet before removing
tmpFirstSet for next input
69             firstSet.addAll(tmpFirstSet);
70             // check if it contains empty, yes -> go
on, no-> break;
71             if(!(tmpFirstSet.contains(new Token("#")))){
72                 // clean tmp
73                 tmpFirstSet.clear();
74                 break;
75             }
76
77             // clean tmp
78             tmpFirstSet.clear();
79             // clean tmp
80             tmpFirstSet.clear();
81         }
82         if (pEmpty) {
83             emptyNum++;
84             // remove empty as there is a choice and it's not
the first level
85             tmpFirstSet.remove(new Token("#"));
86             firstSet.remove(new Token("#"));
87         }

```

```

88         }
89     }
90     // when all choices contain a empty
91     if (emptyNum == tokens.size()) {
92         tmpFirstSet.add(new Token("#"));
93         firstSet.add(new Token("#"));
94     }
95
96 }
97 // add to first map
98 first.put(production.index, firstSet);
99 // clean for next
100 firstEmpty.put(production.index, pEmpty);
101 return pEmpty;
102 }

```

FOLLOW集

```

1  /**
2   * getFirst() should be used for calling this start index given '!' as
the
3   * parentheses, '#' as empty
4   */
5  public void getFollow() {
6      assert (!first.isEmpty());
7      boolean changed = false;
8      do {
9          // update status
10         followSetChanged = new HashMap<>();
11         // start '!'
12         Set<Token> s = follow.get(grammar.getStartToken());
13         if (s == null) {
14             s = new HashSet<>();
15         }
16         s.add(new Token("!"));
17         follow.put(grammar.getStartToken(), s);
18         // production with index k
19         for (Entry<NonTerminal, Production> e : productions.entrySet())
{
20             NonTerminal k = e.getKey();
21             // index set
22             Set<NonTerminal> keySet = first.keySet();
23             Production v = e.getValue();
24             // a production
25             for (Vector<Token> production : v.target) {
26                 // a token
27                 for (int i = 0; i < production.size(); i++) {
28                     Token t = production.get(i);
29                     // only for keySet
30                     if (keySet.contains(t.toNonTerminal())) {
31                         // remember to change the type of equal() will
get wrong.
32                         NonTerminal tt = t.toNonTerminal();
33                         // check i last one
34                         if (i == production.size() - 1) {
35                             Set<Token> set = follow.get(tt);
36                             if (set == null) {

```

```

37         set = new HashSet<>();
38     }
39     Set<Token> stmp = follow.get(k);
40     if (stmp == null) {
41         stmp = new HashSet<>();
42     }
43     // record
44     followSetChanged.put(tt, set.addAll(stmp));
45     follow.put(tt, set);
46 } else {
47     // terminal next
48     Token n = production.get(i + 1);
49     if (isTer(n)) {
50         Set<Token> set = follow.get(tt);
51         if (set == null) {
52             set = new HashSet<>();
53         }
54         // record
55         followSetChanged.put(tt, set.add(n));
56         follow.put(tt, set);
57         // nonTerminal
58     } else {
59         // next
60         Set<Token> set =
first.get(n.toNonTerminal());
61         Set<Token> stmp = follow.get(tt);
62         if (stmp == null) {
63             stmp = new HashSet<>();
64         }
65         // if there's empty
66         if (set.contains(new Token("#"))) {
67             // add follow index
68             Set<Token> tmp = follow.get(k);
69             if (tmp == null) {
70                 tmp = new HashSet<>();
71             }
72             set.addAll(tmp);
73         }
74         // for(Iterator<Token> iterator =
set.iterator();iterator.hasNext();) { Token
75             // token = iterator.next();
76             if(token.context == "#"){
77                 // iterator.remove(); } } I leave the
code here to suggest that iterator
78                 // will remove everything from
source[HashMap first] be careful filter not empty
79                 Set<Token> tmp = new HashSet<>();
80                 for (Token token : set) {
81                     if (token.context != "#")
82                         tmp.add(token);
83                 }
84                 set = tmp;
85                 // record
86                 followSetChanged.put(tt,
stmp.addAll(set));
87                 follow.put(tt, stmp);
88             }
}

```

```

89         }
90     }
91 }
92
93 }
94
95 // get changed
96 changed = followSetChanged.containsValue(true);
97 } while (changed);
98 }

```


SELECT集

```

1  /**
2   * should make sure getFirst and getFollow are done before.
3   */
4  public void getSelect() {
5      assert (!first.isEmpty() && !follow.isEmpty());
6      // iterate all productions
7      productions.forEach((k, v) -> {
8          // split productions
9          v.target.forEach(p -> {
10             // check if the target production is empty
11             HashSet<Token> firstSet = new HashSet<>();
12             Set<Token> tmpFirstSet = new HashSet<>();
13             Production pNew = new Production(k, p);
14             boolean isEmpty = checkProductionFirst(firstSet,
15 tmpFirstSet, pNew);
16             if (isEmpty) {
17                 firstSet.remove(new Token("#"));
18                 firstSet.addAll(follow.get(k));
19             }
20             select.put(pNew, firstSet);
21         });
22     });
23 }

```

我用书上的P72页例题4.5文法，P92 的例题测试，得到所有的结果皆通过。



其中一个测试用例：

```
1 @Test
```

```

2      void followTest_2() throws Exception {
3          // Page 93
4          String test = "E TA;A +TA;A #;T FB;B *FB;B #;F i;F (E)";
5          Grammar grammar = new Grammar(new NonTerminal("E"),
Production.translate(test));
6          parser = new Parser(grammar);
7          parser.getFirst();
8          parser.getFollow();
9          HashMap<NonTerminal, Set<Token>> follow = parser.follow;
10         assertEquals(new HashSet<>(Arrays.asList(new Token("!"),new
Token(")"))),
11             follow.get(new NonTerminal("E")), "first set fails.");
12
13         assertEquals(new HashSet<>(Arrays.asList(new Token(")"),new
Token("!"))),
14             follow.get(new NonTerminal("A")), "first set fails.");
15
16         assertEquals(new HashSet<>(Arrays.asList(new Token("+"),new
Token("!"),new Token(")"))),
17             follow.get(new NonTerminal("B")), "first set fails.");
18     }

```

测试

输入测试用例

```
1 | (a+15)*b
```

引用文章

[1]: by Eli Bendersky, 2003. <http://archive.gamedev.net/archive/reference/programming/features/af1/index.html>Copyright

[2]: Dragon Book, Aho, Sethi, Ullman, *Compilers: Principles, Techniques, and Tools*, Addison-Wesley, 1986. ISBN 0-201-10088-6, 2ed.

附录

EBNF 的元符号

‘<>’ 是用左右尖括号括起来的中文字表示语法构造成分，或称语法单位，为非终结符。

‘::=’ 该符号的左部由右部定义，可读作‘定义为’

‘|’ 表示‘或’，即左部可由多个右部定义

‘{ }’ 表示花括号内的语法成分可以重复；在不加上下界时可重复0到任意次数，有上下界时为可重复次数的限制

‘[]’ 表示方括号内的成分为任选项

‘()’ 表示圆括号内的成分优先

序号	类别	单词	编码
1	基本字	begin、call、const、do、end、if、odd、procedure、read、then、var、while、write	beginsym, callsym, constsym dosym, endsym, ifsym, oddsym proceduresym, readsym, thensym varsym, whilesym, writesym
2	标识符	ident	
3	常数	number	
4	运算符	+, -, *, /, =, #, <, <=, >, >=, :=	plus, minus, times, slash, eql, neq, lss, leq, gtr, geq, becomes
5	界符	(,), , , : , .	Lparen, rparen, comma, semicolon period

ASCII

ASCII TABLE

Decimal	Hexadecimal	Binary	Octal	Char	Decimal	Hexadecimal	Binary	Octal	Char	Decimal	Hexadecimal	Binary	Octal	Char
0	0	0	0	[NULL]	48	30	110000	60	0	96	60	1100000	140	`
1	1	1	1	[START OF HEADING]	49	31	110001	61	1	97	61	1100001	141	a
2	2	10	2	[START OF TEXT]	50	32	110010	62	2	98	62	1100010	142	b
3	3	11	3	[END OF TEXT]	51	33	110011	63	3	99	63	1100011	143	c
4	4	100	4	[END OF TRANSMISSION]	52	34	110100	64	4	100	64	1100100	144	d
5	5	101	5	[ENQUIRY]	53	35	110101	65	5	101	65	1100101	145	e
6	6	110	6	[ACKNOWLEDGE]	54	36	110110	66	6	102	66	1100110	146	f
7	7	111	7	[BELL]	55	37	110111	67	7	103	67	1100111	147	g
8	8	1000	10	[BACKSPACE]	56	38	111000	70	8	104	68	1101000	150	h
9	9	1001	11	[HORIZONTAL TAB]	57	39	111001	71	9	105	69	1101001	151	i
10	A	1010	12	[LINE FEED]	58	3A	111010	72	:	106	6A	1101010	152	j
11	B	1011	13	[VERTICAL TAB]	59	3B	111011	73	;	107	6B	1101011	153	k
12	C	1100	14	[FORM FEED]	60	3C	111100	74	<	108	6C	1101100	154	l
13	D	1101	15	[CARRIAGE RETURN]	61	3D	111101	75	=	109	6D	1101101	155	m
14	E	1110	16	[SHIFT OUT]	62	3E	111110	76	>	110	6E	1101110	156	n
15	F	1111	17	[SHIFT IN]	63	3F	111111	77	?	111	6F	1101111	157	o
16	10	10000	20	[DATA LINK ESCAPE]	64	40	1000000	100	@	112	70	1110000	160	p
17	11	10001	21	[DEVICE CONTROL 1]	65	41	1000001	101	A	113	71	1110001	161	q
18	12	10010	22	[DEVICE CONTROL 2]	66	42	1000010	102	B	114	72	1110010	162	r
19	13	10011	23	[DEVICE CONTROL 3]	67	43	1000011	103	C	115	73	1110011	163	s
20	14	10100	24	[DEVICE CONTROL 4]	68	44	1000100	104	D	116	74	1110100	164	t
21	15	10101	25	[NEGATIVE ACKNOWLEDGE]	69	45	1000101	105	E	117	75	1110101	165	u
22	16	10110	26	[SYNCHRONOUS IDLE]	70	46	1000110	106	F	118	76	1110110	166	v
23	17	10111	27	[ENG OF TRANS. BLOCK]	71	47	1000111	107	G	119	77	1110111	167	w
24	18	11000	30	[CANCEL]	72	48	1001000	110	H	120	78	1111000	170	x
25	19	11001	31	[END OF MEDIUM]	73	49	1001001	111	I	121	79	1111001	171	y
26	1A	11010	32	[SUBSTITUTE]	74	4A	1001010	112	J	122	7A	1111010	172	z
27	1B	11011	33	[ESCAPE]	75	4B	1001011	113	K	123	7B	1111011	173	{
28	1C	11100	34	[FILE SEPARATOR]	76	4C	1001100	114	L	124	7C	1111100	174	
29	1D	11101	35	[GROUP SEPARATOR]	77	4D	1001101	115	M	125	7D	1111101	175	}
30	1E	11110	36	[RECORD SEPARATOR]	78	4E	1001110	116	N	126	7E	1111110	176	~
31	1F	11111	37	[UNIT SEPARATOR]	79	4F	1001111	117	O	127	7F	1111111	177	[DEL]
32	20	100000	40	[SPACE]	80	50	1010000	120	P					
33	21	100001	41	!	81	51	1010001	121	Q					
34	22	100010	42	"	82	52	1010010	122	R					
35	23	100011	43	#	83	53	1010011	123	S					
36	24	100100	44	\$	84	54	1010100	124	T					
37	25	100101	45	%	85	55	1010101	125	U					
38	26	100110	46	&	86	56	1010110	126	V					
39	27	100111	47	'	87	57	1010111	127	W					
40	28	101000	50	(88	58	1011000	130	X					
41	29	101001	51)	89	59	1011001	131	Y					
42	2A	101010	52	*	90	5A	1011010	132	Z					
43	2B	101011	53	+	91	5B	1011011	133	[
44	2C	101100	54	,	92	5C	1011100	134	\					
45	2D	101101	55	-	93	5D	1011101	135]					
46	2E	101110	56	.	94	5E	1011110	136	^					
47	2F	101111	57	/	95	5F	1011111	137	_					

JAVA SE 14

[Java® Platform, Standard Edition & Java Development Kit](#)
[Version 14 API Specification](#)

[#词法分析]:
[#定义Tag类]: